

WEEK-003: Week 3 (2026-03-10 ~ 2026-03-14)

Goals

- ☒ 完成各模块性能测试和精度测试
- ☒ 优化stageA_encoder性能瓶颈
- ☒ 提升模型精度
- ☒ 完成模型量化
- ☒ 完成融合模型初步评估
- ☐ 优化bev_pool性能瓶颈

Completed

1. 性能优化

- 完成各模块性能测试，识别stageA_encoder为主要瓶颈(178.9ms, 72.69%)
- 通过msprof工具分析，发现ScatterNdUpdate算子占比80%以上
- 实施优化：将索引赋值操作改为拼接操作(见PERF-005)
- 优化效果：stageA_encoder从178.9ms降至41ms，NPU总耗时从246ms降至108ms

2. 精度提升

- 决策：将体素化数量上限从6000增加到10000(见D-004)
- 效果：mAP从0.189提升到0.219，提升15.9%
- 代价：推理耗时从108ms增加到132ms

3. 模型量化

- 决策：使用FP16量化策略(见D-005)
- 效果：推理耗时从132ms降至102ms，mAP仅从0.219降至0.218
- 全流程pipeline从0.25s降至0.22s

4. LiDAR分支完整评估

- 完成全流程计时统计(见EVAL-004)
- mAP: 0.2186
- 单样本总耗时: 18.559s (Mean: 229.1ms)

5. 融合模型初步评估

- 完成LiDAR+Camera融合模型端到端推理
- 识别bev_pool为主要性能瓶颈(134.97ms)
- 发现融合推理耗时高达1427ms，主要由于数据拷入/拷出频繁
- mAP: 0.217

6. 其他尝试

- 尝试MatMul替代Scatter：未实现更优
- 尝试index_add → ScatterAdd：未实现更优
- 尝试AOE工具调优：难以提高性能

Blockers

- **bev_pool性能瓶颈**: 融合模型推理耗时高达1427ms，bev_pool单独作为OM模型推理耗时达1300ms
- **NPU不擅长bev_pool计算**: bev_pool主要计算是将特征撒在BEV网格中，这种计算NPU不擅长
- **融合模型精度略降**: 融合后mAP(0.217)略低于LiDAR单独(0.2186)

Next Week Plan

1. 学习AscendC算子设计
2. 将bev_pool设计为自定义NPU算子
3. 优化融合模型数据传输流程
4. 进一步提升融合模型精度

Metrics

Metric	Value
Performance Reports	1 (PERF-005)
Decision Logs	2 (D-004, D-005)
Evaluation Reports	1 (EVAL-004)
LiDAR mAP	0.2186
Fusion mAP	0.217
LiDAR Inference	102ms
Fusion Inference	1427ms